

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỀ CƯƠNG THỰC TẬP CƠ SỞ

ĐỀ TÀI:

**Nghiên cứu học đa nhiệm và cơ chế Attention trong bài toán
phân đoạn và phân loại u não từ ảnh MRI**

Giảng viên hướng dẫn: TS.Kim Ngọc Bách

Sinh viên thực hiện: Đặng Tuấn Minh

Mã Sinh Viên: B23DCCN539

HÀ NỘI, THÁNG 6/2026

I) Giới thiệu chung.....	3
1. Lý do chọn đề tài.....	3
2. Ý nghĩa của đề tài.....	3
3. Tính ứng dụng và giá trị thực tiễn.....	3
4. Giá trị học thuật.....	4
II) Cơ sở lý thuyết và công nghệ sử dụng.....	4
A. Kiến thức tổng quan về các loại khối u.....	4
1. Glioma.....	4
2. Meningioma.....	5
3. Pituitary.....	5
4. Non-Tumor.....	5
B. Tổng quan về Dataset.....	6
C. Các model sử dụng trong dự án.....	7
1. UNET.....	7
2. Attention Unet.....	7
3. Unet Encoder + Classifier.....	9
4. Joint Training.....	9
D. Loss function và Evaluation metric.....	12
1. Cross-Entropy Loss.....	12
2. Dice Loss.....	13
3. Combo Loss.....	13
4. Evaluation Metrics.....	14
Đối với lớp glioma.....	15
Precision.....	16
Recall.....	16
III) Phân tích và thiết kế hệ thống.....	19
A. Kiến trúc hệ thống tổng thể.....	19
B. Thiết kế model.....	19
IV) Kết quả cài đặt và thử nghiệm.....	21
A. Chiến lược Training.....	21
Classification.....	22
Segmentation.....	22
B. Kết quả thử nghiệm.....	25
C. Hình ảnh demo.....	27
V) Kết Luận.....	35
TÀI LIỆU THAM KHẢO.....	36

I) Giới thiệu chung

1. Lý do chọn đề tài

Ung thư não là một trong những bệnh lý thần kinh nguy hiểm với tỷ lệ tử vong cao và yêu cầu chẩn đoán sớm để nâng cao hiệu quả điều trị. Trong thực tế lâm sàng, việc phân tích ảnh MRI thường phụ thuộc nhiều vào kinh nghiệm của bác sĩ chuyên khoa, dẫn đến nguy cơ sai lệch do tính chủ quan và thời gian xử lý lớn.

Sự phát triển mạnh mẽ của Deep Learning, đặc biệt là các kiến trúc Convolutional Neural Network (CNN), đã mở ra hướng tiếp cận mới trong tự động hóa phân tích ảnh y tế.

Trong đó, các mô hình như U-Net và các biến thể của nó đã chứng minh hiệu quả vượt trội trong bài toán phân đoạn ảnh y khoa.

Từ thực tiễn đó, đề tài được lựa chọn nhằm xây dựng một hệ thống hỗ trợ phân tích ảnh MRI não tự động, kết hợp đồng thời hai nhiệm vụ quan trọng: phân loại loại u và phân đoạn vùng u, dựa trên các mô hình học sâu hiện đại.

2. Ý nghĩa của đề tài

Đề tài mang ý nghĩa quan trọng ở cả góc độ kỹ thuật và y học:

- Về mặt kỹ thuật, hệ thống triển khai kiến trúc **multi-task learning**, cho phép một mô hình học đồng thời nhiều nhiệm vụ, giúp tối ưu hóa việc khai thác đặc trưng dữ liệu và cải thiện hiệu suất tổng thể.
- Về mặt y học, hệ thống cung cấp công cụ hỗ trợ phân tích ảnh MRI, giúp tự động xác định vùng u và phân loại loại u não, từ đó hỗ trợ bác sĩ trong quá trình chẩn đoán.
- Về mặt nghiên cứu, đề tài tích hợp nhiều kiến trúc deep learning khác nhau (U-Net, Attention U-Net, Classification model, Multi-task model), tạo điều kiện so sánh và đánh giá hiệu quả giữa các phương pháp.

3. Tính ứng dụng và giá trị thực tiễn

Hệ thống được thiết kế theo hướng end-to-end và có khả năng triển khai thực tế thông qua giao diện web Flask, cho phép người dùng tải ảnh MRI và nhận kết quả dự đoán trực quan.

Các ứng dụng cụ thể bao gồm:

- Hỗ trợ bác sĩ trong việc phân tích nhanh ảnh MRI não
- Tự động hóa quy trình chẩn đoán sơ bộ
- Trực quan hóa vùng u trên ảnh y tế
- So sánh kết quả giữa nhiều mô hình để tăng độ tin cậy

Ngoài ra, hệ thống còn có khả năng mở rộng để tích hợp vào các hệ thống hỗ trợ chẩn đoán (Clinical Decision Support Systems - CDSS).

4. Giá trị học thuật

Đề tài có giá trị học thuật thể hiện qua việc kết hợp và triển khai nhiều hướng nghiên cứu trong Deep Learning hiện đại:

- **U-Net architecture**: nền tảng cho segmentation trong y học
- **Attention mechanism**: cải thiện khả năng tập trung vào vùng quan trọng
- **Multi-task learning**: chia sẻ encoder giữa classification và segmentation
- **Hybrid loss functions**: kết hợp BCE, Dice Loss và CrossEntropy
- **Model comparison framework**: đánh giá nhiều kiến trúc trong cùng hệ thống

Bên cạnh đó, việc xây dựng pipeline hoàn chỉnh từ training đến deployment (Flask) giúp mô hình không chỉ mang tính nghiên cứu mà còn có khả năng ứng dụng thực tế cao.

II) Cơ sở lý thuyết và công nghệ sử dụng

A. Kiến thức tổng quan về các loại khối u

U não là một trong những loại ung thư có tỷ lệ tử vong cao nhất. Trong nhóm các khối u rắn ở trẻ em, u não vừa là loại phổ biến vừa có mức độ nguy hiểm cao. Các khối u não rất đa dạng về mặt bệnh học, trong đó u thần kinh đệm (glioma) chiếm khoảng 45% tổng số ca, còn u tuyến yên và u màng não mỗi loại chiếm khoảng 15%. Phương pháp chẩn đoán hình ảnh tiêu chuẩn vàng cho u não hoặc di căn não là chụp cộng hưởng từ (MRI) có tiêm gadolinium. Khi có thể, phương pháp điều trị ban đầu thường là phẫu thuật nhằm loại bỏ khối u, sau đó mẫu bệnh phẩm được phân tích mô học và kiểu gen phân tử. Các ảnh MRI trước, trong và sau phẫu thuật được sử dụng để hỗ trợ quá trình cắt bỏ khối u và quản lý điều trị. Trong quá trình phẫu thuật, MRI chức năng cho phép quan sát hoạt động mạch máu não, từ đó suy ra hoạt động thần kinh và hỗ trợ đội ngũ phẫu thuật. Ngoài ra, các kỹ thuật khác như mô phỏng tùy sống cũng có thể được sử dụng. Tuy nhiên, do sự tồn tại của nhiều vùng chức năng quan trọng trong não, phạm vi can thiệp phẫu thuật thường bị giới hạn để đảm bảo an toàn. Các phương pháp điều trị bổ sung bao gồm điều trị nội khoa nhằm kiểm soát triệu chứng, xạ trị và hóa trị. Hàng rào máu não gây ra nhiều thách thức cho các phương pháp điều trị nội khoa và hóa trị vì nó hạn chế sự xâm nhập của các chất từ hệ tuần hoàn vào não. Việc xác định chính xác vị trí khối u và các cấu trúc lân cận thông qua MRI đóng vai trò quan trọng trong lập kế hoạch phẫu thuật và xạ trị. Tóm lại, MRI được sử dụng xuyên suốt từ chẩn đoán ban đầu đến lập kế hoạch điều trị và theo dõi u não.

1. Glioma

U thần kinh đệm (glioma) là các khối u não nguyên phát và là loại u ác tính nguyên phát phổ biến nhất ở người trưởng thành. Chúng phát sinh từ các tế bào thần kinh đệm hoặc tế bào gốc có khả năng biệt hóa thành tế bào thần kinh đệm trong quá trình biến đổi tân sinh. Tế bào thần kinh đệm là nhóm tế bào hỗ trợ cho neuron, ví dụ như tham gia hình thành bao myelin của sợi trục. Ở người trưởng thành, dạng ác tính nhất của glioma là

glioblastoma có thời gian sống trung bình khoảng hai năm. Glioma được phân loại theo hệ thống phân loại khối u hệ thần kinh trung ương của WHO năm 2016. Các dạng glioma lan tỏa có thể phát triển với hình dạng không đều và xâm lấn rộng vào nhu mô não, gây khó khăn cho phẫu thuật vì cần bảo tồn các vùng chức năng quan trọng của não.

2.Meningioma

U màng não (meningioma) là loại u phổ biến nhất ở người trưởng thành, chiếm khoảng 30% các khối u hệ thần kinh trung ương, nhưng hiếm gặp ở trẻ em. Chúng phát sinh từ các tế bào nằm ở lớp ngoài của màng nhện, một thành phần của màng não bao quanh não, dịch não tủy và tủy sống. Mặc dù có thể xuất hiện ở bất kỳ vị trí nào trên màng não, khoảng 98% u màng não nằm trong sọ. Phần lớn u màng não là lành tính và phát triển chậm. MRI kết hợp với CT thường được sử dụng trong chẩn đoán và lập kế hoạch điều trị. Phương pháp điều trị chủ yếu là phẫu thuật thần kinh, đôi khi kết hợp với xạ trị. Các u lành tính có thể phát triển đến kích thước lớn, gây chèn ép não và xuất hiện triệu chứng lâm sàng. Ngược lại, các u không lành tính thường có hình dạng không đều và tính không đồng nhất cao, trong khi u lành tính thường có hình dạng đều và đồng nhất hơn.

3. Pituitary

U tuyến yên là các khối u phát sinh từ tuyến yên, một cấu trúc nhỏ nằm ở đáy não, phía trên xương bướm. Tuyến yên đóng vai trò quan trọng trong điều hòa tăng trưởng, chuyển hóa và sinh sản. Do đó, các khối u tại đây có thể gây ra nhiều triệu chứng khác nhau như rối loạn tâm trạng, đái tháo đường, béo phì, vô sinh và rối loạn thị giác. Tuy nhiên, chỉ khoảng một phần ba số trường hợp biểu hiện triệu chứng. Phần lớn u tuyến yên là lành tính, và phương pháp điều trị thường bao gồm phẫu thuật cắt bỏ kết hợp với xạ trị khi cần thiết.

4. Non-Tumor

Các tình trạng không phải u trong tập dữ liệu bao gồm cả các ảnh não bình thường (không có bất thường rõ ràng) và các tổn thương không tân sinh có thể có biểu hiện giống khối u nhưng không phải do quá trình ung thư. Những tổn thương này có thể bao gồm các bệnh lý viêm hoặc mạch máu như áp xe, nang, tụ máu hoặc phình mạch. Việc đưa các trường hợp này vào tập dữ liệu giúp mở rộng phổ biểu hiện hình ảnh trong lâm sàng và hỗ trợ mô hình học tốt hơn trong việc phân biệt giữa tổn thương u và không phải u. Nhờ độ nhạy cao của MRI đối với mô mềm, nhiều trường hợp có thể được đánh giá dựa trên hình ảnh học, mặc dù trong thực tế, việc xác nhận chẩn đoán bằng mô bệnh học (ví dụ sinh thiết) vẫn có thể cần thiết.

B. Tổng quan về Dataset

Bộ dữ liệu Phân đoạn và Phân loại Hình ảnh U não (BRISC) đã được tuyển chọn kỹ lưỡng để giải quyết các khó khăn chính trong nghiên cứu u não, đặc biệt là trong các lĩnh vực phân đoạn và phân loại. Nó cung cấp một bộ sưu tập dữ liệu MRI cân bằng, chất lượng cao, được chú thích cho cả ứng dụng nghiên cứu và lâm sàng. Bộ dữ liệu bao gồm các hình ảnh có nhãn cho bốn loại: U thần kinh đệm, U màng não, U tuyến yên và không có u.

Bảng 1 : Phân bố số lượng ảnh theo từng lớp trong tập training và testing


Class	Training	Testing	Total
Glioma	1147	254	1401
Meningioma	1329	306	1635
Pituitary	1457	300	1757
non-tumorous	1067	140	1207
Total	5000	1000	6000

Định hướng và mục tiêu

Mục tiêu chính của việc thu thập và phát hành bộ dữ liệu này là để khắc phục những hạn chế được quan sát thấy trong các bộ dữ liệu u não hiện có, chẳng hạn như sự mất cân bằng lớp, thiếu đa dạng và sự không nhất quán trong chú thích. Mặc dù các bộ dữ liệu như BraTS đã thúc đẩy những tiến bộ đáng kể trong việc phân đoạn u thần kinh đệm, nhưng việc chỉ tập trung vào u thần kinh đệm và dựa vào dữ liệu được xử lý trước đã hạn chế khả năng áp dụng của chúng cho các loại u khác và các tình huống thực tế. Bộ dữ liệu của chúng tôi mở rộng phạm vi bằng cách kết hợp nhiều loại u và bao gồm một lớp "không phải u" để hỗ trợ các nhiệm vụ chẩn đoán rộng hơn. Việc bổ sung này làm cho bộ dữ liệu trở nên rất linh hoạt, cho phép sử dụng nó trong các ứng dụng từ phân loại u đa lớp đến phát hiện u nhị phân.

C. Các model sử dụng trong dự án

1. UNET



Kiến trúc mạng được minh họa trong Hình 1, bao gồm hai phần chính là nhánh co (bên trái) và nhánh giãn (bên phải). Nhánh co tuân theo cấu trúc điển hình của một mạng tích chập, trong đó các khối được xây dựng bằng cách lặp lại hai phép tích chập kích thước 3x3 (không sử dụng padding), mỗi phép đều đi kèm với hàm kích hoạt ReLU, sau đó là một lớp gộp cực đại 2x2 với bước trượt bằng 2 để thực hiện giảm kích thước không gian. Sau mỗi lần giảm mẫu, số lượng kênh đặc trưng được tăng gấp đôi nhằm nâng cao khả năng biểu diễn. Ở nhánh giãn, mỗi bước bao gồm việc tăng kích thước bản đồ đặc trưng (upsampling), tiếp theo là một phép tích chập 2x2 (up-convolution) để giảm một nửa số kênh đặc trưng. Sau đó, đặc trưng này được nối (concatenate) với bản đồ đặc trưng tương ứng từ nhánh co đã được cắt (cropping) để đảm bảo kích thước phù hợp, do việc mất thông tin biên trong quá trình tích chập không padding. Tiếp theo là hai phép tích chập 3x3, mỗi phép đều đi kèm với hàm kích hoạt ReLU nhằm tinh chỉnh đặc trưng. Ở lớp cuối cùng, một phép tích chập 1x1 được sử dụng để ánh xạ mỗi vector đặc trưng gồm 64 thành phần sang số lượng lớp đầu ra mong muốn. Tổng thể, mạng bao gồm 23 lớp tích chập.

2. Attention Unet

2.1. Định nghĩa Attention

Cơ chế Attention trong U-Net là một phương pháp giúp làm nổi bật chỉ những kích hoạt có liên quan trong quá trình huấn luyện. Nó giúp giảm thiểu tài nguyên tính toán bị lãng phí vào các kích hoạt không liên quan và mang lại khả năng khái quát hóa tốt hơn cho mạng.

Có 2 loại attention:

- Cơ chế chú ý cứng (Hard attention):

Làm nổi bật các vùng quan trọng bằng cách cắt xén. Chỉ một vùng của ảnh được xử lý tại một thời điểm; điều này có nghĩa là nó không thể phân biệt được và cần đến học tăng cường (reinforcement learning). Mạng chỉ có thể chú ý hoặc không, không có trạng thái trung gian.


Không thể sử dụng lan truyền ngược (backpropagation).

- Cơ chế chú ý mềm (Soft attention):

Gán trọng số cho các phần khác nhau của ảnh. Các phần quan trọng của ảnh nhận được trọng số lớn và các phần ít quan trọng hơn nhận được trọng số nhỏ. Có thể được huấn luyện bằng lan truyền ngược. Trong quá trình huấn luyện, trọng số cũng được huấn luyện, giúp mô hình chú ý nhiều hơn đến các vùng quan trọng. Tóm lại – nó thêm trọng số cho các pixel dựa trên mức độ quan trọng.

2.2. Attention Gate

Kết nối bỏ qua (skip connection) của U-net kết hợp thông tin không gian từ đường dẫn lấy mẫu giảm (down-sampling) với đường dẫn lấy mẫu tăng (up-sampling) để giữ lại thông tin không gian tốt. Tuy nhiên, quá trình này lại mang theo sự biểu diễn đặc trưng kém từ các lớp ban đầu. Cơ chế chú ý mềm (soft attention) được triển khai tại các kết nối bỏ qua sẽ chủ động ngăn chặn các kích hoạt tại các vùng không liên quan.




Attention gate có 2 đầu vào, x và g

- g , gating signal, comes from the next lowest layer of the network.

Bởi vì nó đến từ lớp sâu hơn của mạng nên nó có những biểu diễn đặc trưng tốt hơn

- x , comes from skip connections

Bởi vì nó đến từ lớp trước đó nên nó có thông tin không gian tốt hơn



3. Unet Encoder + Classifier

Sử dụng encoder của Unet để trích xuất đặc trưng, đầu phân loại là mạng kết nối hoàn toàn

4. Joint Training

4.1 Tìm hiểu về Multitask Learning trong Medical Imaging

Giới thiệu


Học đa nhiệm (MTL) là một phương pháp học sâu nhằm mục đích học đồng thời hai hoặc nhiều nhiệm vụ cùng nhau để tận dụng kiến thức được chia sẻ giữa các nhiệm vụ. Kiến thức được chia sẻ này giúp cải thiện hiệu suất của từng nhiệm vụ. Theo truyền thống, các mô hình học sâu được huấn luyện để thực hiện một nhiệm vụ duy nhất; tuy nhiên, các mô hình đơn nhiệm truyền thống này yêu cầu rất nhiều dữ liệu huấn luyện, điều này không dễ dàng có được trong một số lĩnh vực như y học và tin sinh học.

4.1.1 Phương pháp MTL Learning

Có bốn phương pháp học chính cho MTL, đó là hard parameter sharing, soft parameter sharing, multi-task attention network, and cross-task attention network.

Hard parameter sharing

Hard parameter sharing trong MTL liên quan đến việc chia sẻ các lớp chung giữa các tác vụ, đặc biệt là các lớp trích xuất đặc trưng, và sau đó mô hình phân nhánh thành các lớp dành riêng cho từng tác vụ như thể hiện trong Hình 3. Chia sẻ tham số cứng cho phép mô hình tìm ra một biểu diễn tổng quát hơn cho tất cả các tác vụ, do đó giảm thiểu nguy cơ quá khớp. Tuy nhiên, cần phải xem xét tính hợp tác so với tính cạnh tranh của các tác vụ liên quan khi thiết kế MTL chia sẻ tham số cứng. Điều này là do chia sẻ tham số cứng là một phương pháp học đặc trưng tập trung vào việc học các đặc trưng chung giữa các tác vụ. Do đó, các tác vụ cạnh tranh sẽ dẫn đến hiệu suất kém vì mô hình sẽ phải vật lộn để đạt được điểm cực tiểu toàn cục của các tác vụ cạnh tranh.



Hình 3

Soft parameter sharing


Soft parameter sharing liên quan đến việc mỗi tác vụ có mô hình và tham số riêng nhưng kiến thức được chia sẻ giữa các tác vụ thông qua regularization. Các kỹ thuật chuẩn hóa phổ biến có thể được sử dụng bao gồm L1 (còn gọi là Lasso) và L2 (còn gọi là chuẩn hóa Ridge). L1 điều chỉnh hàm mất mát bằng cách thêm một số hạng phạt bằng với giá trị tuyệt đối của trọng số của hàm mất mát. Nó có thể được biểu diễn bằng toán học như sau:

$$Loss(L1) = Loss(X) + \lambda \sum_i |w_i|.$$

Mặt khác, L2 lập luận về hàm mất mát bằng cách thêm một hình phạt bằng tổng bình phương các giá trị của hàm mất mát. Nó có thể được biểu diễn bằng toán học như sau:

$$Loss(L2) = Loss(X) + \lambda \sum_i |w_i^2|.$$

Loss (X) biểu thị hàm mất mát gốc như mất mát entropy chéo hoặc sai số bình phương trung bình, λ biểu thị một siêu tham số xác định độ mạnh của việc điều chỉnh và các hệ số của mô hình được biểu thị bằng w_i .



Multi-task attention network

Multi-task attention network (MTAN) được giới thiệu bởi Liu et al., (2019) bao gồm các lớp trích xuất đặc trưng được chia sẻ nhưng với cơ chế chú ý mềm cho mỗi nhiệm vụ. Cơ chế chú ý cho phép tối ưu hóa việc học các đặc trưng cụ thể của nhiệm vụ từ bộ trích xuất đặc trưng được chia sẻ trong khi vẫn cho phép các đặc trưng được chia sẻ giữa các nhiệm vụ. Kim et al., (2023) lập luận rằng mặc dù MTAN đã trở nên rất phổ biến trong xử lý ảnh y tế do khả năng phân tích các đặc trưng cấp pixel, nhưng nó gặp khó khăn trong lĩnh vực xử lý ảnh y tế vì nhiều ảnh y tế thiếu các đặc trưng cấp pixel rõ ràng. Để giải quyết khoảng trống này, Kim et al., (2023) đã đề xuất một mạng chú ý đa nhiệm (CTAN).

Cross-task attention network

Cross-task attention network (CTAN) là một khung lai có thể xử lý cả các đặc trưng cấp độ hình ảnh và các đặc trưng cấp độ pixel. Nó bao gồm một bộ mã hóa chú ý đa nhiệm và một nút thắt chú ý đa nhiệm. Bộ mã hóa chú ý đa nhiệm trích xuất thông tin cụ thể của nhiệm vụ trong bộ mã hóa theo cách tương tự như các mô-đun chú ý trong MTAN. Nút thắt chú ý đa nhiệm nắm bắt các tương tác giữa các nhiệm vụ.

Trong dự án này, em sử dụng phương pháp Hard parameter sharing vì model của em sử dụng Unet chia sẻ phần encoder cho cả 2 task: phân loại và phân đoạn, và chia ra các đầu giải mã riêng biệt cho mỗi task.

4.1.2. Task Combinations

Standley và cộng sự (2020) lập luận rằng trong thiết lập MTL, tất cả các tác vụ đều có khả năng cải thiện hiệu suất nếu chúng hợp tác với nhau tác vụ. Cũng có thể một số tác vụ hỗ trợ các tác vụ khác cải thiện hiệu suất trong khi bản thân chúng không cải thiện hiệu suất. Những tác vụ như vậy được gọi là tác vụ hướng dẫn mất mát hoặc tác vụ dư thừa. Trong lĩnh vực xử lý hình ảnh y tế, nhiều tác vụ đơn lẻ có thể được đưa vào thiết lập đa tác vụ. Chúng bao gồm; phân đoạn, phân loại, hồi quy, phát hiện đối tượng và tái tạo, trong số những tác vụ khác.

Rõ ràng là việc xác định các nhiệm vụ cần đưa vào mô hình MTL nên được dựa trên việc liệu các nhiệm vụ đó có thể được chia thành các nhiệm vụ riêng lẻ hay không. Do đó, một mô hình MTL có thể được coi là đúng nếu mỗi nhiệm vụ có thể được liên kết với một hàm mất mát. Một chủ đề đáng chú ý trong nghiên cứu này là đề quá trình học tập chung diễn ra, phần lớn các nghiên cứu được xem xét đã xây dựng một hàm mất mát kết hợp xem xét các hàm mất mát cụ thể của từng nhiệm vụ. Ví dụ: cho ba nhiệm vụ T_a , T_b và T_c , và cho các hàm mất mát của chúng là L_a , L_b và L_c , thì hàm mất mát kết hợp có thể được xây dựng như sau:

$$L_{combined} = \lambda_1 L_a + \lambda_2 L_b + \lambda_3 L_c$$

Trong đó λ_1 , λ_2 và λ_3 là các trọng số cho từng hàm mất mát riêng lẻ.

D. Loss function và Evaluation metric

1. Cross-Entropy Loss

Entropy chéo (CE) đo lường sự khác biệt giữa hai phân phối xác suất cho một biến ngẫu nhiên nhất định. Trong các nhiệm vụ phân đoạn, tổn thất entropy chéo được sử dụng để đo lường mức độ phù hợp giữa dự đoán của mô hình với nhãn mục tiêu. Sử dụng hàm softmax, mô hình tạo ra bản đồ xác suất theo từng pixel thể hiện khả năng mỗi pixel thuộc về mỗi lớp. Sau đó, tổn thất entropy chéo được tính bằng cách lấy logarit âm của xác suất dự đoán cho lớp mục tiêu tại mỗi pixel. Tổn thất entropy chéo tiến đến 0 khi xác suất dự đoán cho lớp mục tiêu tiến đến 1.

$$L_{CE}(y, t) = - \sum_{n=1}^N \log(t_n \cdot y_n) \quad (1)$$

As t_n is a one-hot encoded vector, only the predicted probability of the target class affects the cross-entropy loss.

Khi xử lý các tập dữ liệu không cân bằng, một cách tiếp cận đối với hàm mất mát entropy chéo là gán trọng số khác nhau cho mỗi lớp. Điều này có thể giúp cân bằng ảnh hưởng của mỗi lớp đến tổn thất tổng thể và cải thiện hiệu suất của mô hình trên các lớp ít được đại diện. Một cách để gán trọng số là sử dụng tần suất nghịch đảo của lớp, có nghĩa là trọng số cho mỗi lớp tỷ lệ nghịch với số lượng mẫu trong lớp đó. Vì vậy, các lớp có ít mẫu hơn sẽ có trọng số cao hơn và các lớp có nhiều mẫu hơn sẽ có trọng số thấp hơn.

$$L_{WCE}(y, t, w) = - \sum_{n=1}^N t_n \cdot w \log(t_n \cdot y_n) \quad (2)$$

Đối với mỗi pixel, trọng số của lớp mục tiêu được sử dụng. Nếu tất cả các trọng số được đặt bằng 1, ta chỉ đơn giản nhận được tổn thất entropy chéo.

2. Dice Loss

Hàm mất mát Dice bắt nguồn từ hệ số Dice, một thước đo độ tương đồng giữa hai tập dữ liệu. Nó thường được sử dụng trong phân đoạn ảnh để đánh giá sự chồng chéo giữa mặt nạ phân đoạn dự đoán và mặt nạ phân đoạn mục tiêu. Nó được định nghĩa là kích thước của phần giao nhau giữa mặt nạ phân đoạn dự đoán và mặt nạ phân đoạn thực tế, chia cho tổng của chúng. Nó được tính toán riêng cho từng lớp và giá trị trung bình được báo cáo. Nó có thể được viết như sau:

$$\text{Dice Coefficient} = \frac{2|Y \cap T|}{|Y| + |T|} \quad (6)$$

trong đó Y là mặt nạ dự đoán phân đoạn nhị phân và T là mặt nạ mục tiêu phân đoạn nhị phân cho một lớp duy nhất. Hệ số Dice thường được sử dụng trong phân đoạn ngữ nghĩa vì nó dễ tính toán, cung cấp một giá trị duy nhất tóm tắt hiệu suất và đạt được sự cân bằng tốt giữa độ chính xác và độ thu hồi. Nó đặc biệt hữu ích khi đối tượng quan tâm nhỏ hoặc hiếm và sự phân bố lớp không cân bằng.

$$L_{dice} = 1 - \frac{1}{C} \sum_{c=0}^{C-1} \frac{2 \sum_{n=1}^N t_n^c y_n^c}{\sum_{n=1}^N (t_n^c + y_n^c)}$$

Nó được tính toán riêng cho từng lớp mục tiêu và giá trị trung bình trên tất cả các lớp được sử dụng. Các dự đoán không được coi là chắc chắn (0, 1) mà được nói lỏng và được coi là xác suất (0, 1). Điều này làm cho hàm mất mát trở nên khả vi và có thể được tối ưu hóa bằng các phương pháp giảm độ dốc. Cuối cùng, hệ số Dice được nói lỏng được trừ đi 1 để biến nó thành một hàm mất mát cần được tối thiểu hóa thay vì tối đa hóa. Đây là một lựa chọn phổ biến cho các tập dữ liệu không cân bằng vì nó ngăn mô hình bỏ qua các lớp thiểu số bằng cách tập trung vào các vùng chồng chéo giữa mặt nạ dự đoán và mặt nạ thực tế.

3. Combo Loss

Trong phân đoạn ngữ nghĩa, phương pháp phổ biến nhất là kết hợp tổn thất Dice và tổn thất entropy chéo có trọng số trong tổn thất Combo để khắc phục vấn đề mất cân bằng lớp. Ở đây, tổn thất entropy chéo có trọng số cho phép khắc phục vấn đề mất cân bằng dữ liệu bằng cách gán trọng số lớn hơn cho các lớp ít được đại diện trong khi tổn thất Dice cho phép phân đoạn các đối tượng nhỏ hơn. Hơn nữa, tổn thất entropy chéo có trọng số

cung cấp độ dốc mượt mà trong khi tổn thất Dice giúp tránh các cực tiểu cục bộ. Nó chỉ đơn giản là cộng tổn thất entropy chéo và tổn thất Dice bằng cách sử dụng một thuật ngữ điều chỉnh để kiểm soát sự đóng góp của mỗi hàm tổn thất, phương trình tổng thể được định nghĩa là:

$$L_{combo} = \alpha L_{WCE} + (1 - \alpha) L_{dice}$$

trong đó α kiểm soát trọng số của tổn thất Dice so với tổn thất entropy chéo có trọng số, và trọng số của entropy chéo kiểm soát lượng trừng phạt của mô hình đối với các lớp mục tiêu khác nhau.

4. Evaluation Metrics

4.1. Metrics cho bài toán phân loại

Đối với bài toán phân loại u não các chỉ số sau được sử dụng

		Actual Values	
		P	N
Predicted Values	P	TP (True Positive)	FP (False Positive)
	N	FN (False Negative)	TN (True Negative)

Accuracy : Tỷ lệ chính xác (accuracy rate) có thể được định nghĩa là số lượng các phân loại đúng chia cho toàn bộ tập kiểm tra, hay nói cách khác là tỷ phần các dự đoán đúng của một bộ phân loại trên toàn bộ tập kiểm tra.

$$\text{Accuracy Rate} = \frac{1}{m} \sum_{i=1}^m I(y_i = \hat{y}_i),$$

Trong đó, I là hàm chỉ thị (indicator function), có giá trị bằng 1 nếu mệnh đề đúng, ngược lại có giá trị bằng 0. m là kích thước của tập kiểm tra.

Precision : là tỷ lệ giữa số lượng dương tính đúng (true positive) trên toàn bộ các trường hợp được dự đoán là dương tính. Tất cả các trường hợp dương tính ở đây bao gồm các dương tính đúng quan sát được, cộng với một số trường hợp âm tính thực sự nhưng bị dự

đoán nhầm thành dương tính (false positive - FP). Về mặt ký hiệu:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall: (còn gọi là sensitivity hoặc true positive rate – tỷ lệ dương tính thật) là khả năng của một mô hình trong việc xác định đúng các trường hợp dương tính thực sự. Về mặt toán học, nó được định nghĩa như sau:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Recall trả lời câu hỏi: trong tất cả các trường hợp dương tính thực sự (bao gồm cả các dương tính đúng và các dương tính thực sự nhưng bị dự đoán nhầm thành âm tính - FN), có bao nhiêu phần trăm được xác định đúng là dương tính? Recall cao nghĩa là số lượng dương tính đúng được phát hiện tương đối lớn so với số lượng âm tính giả (false negative). Ngược lại, recall thấp nghĩa là số lượng dương tính đúng được phát hiện ít hơn so với số lượng âm tính giả.

F1-Score: F1-Score là trung bình điều hòa (harmonic mean) hoặc trung bình có trọng số của precision và recall. Theo định nghĩa, đây là một thước đo độ chính xác của một phép kiểm tra, được tính từ precision và recall của phép kiểm tra đó. Như đã đề cập, precision là số lượng kết quả dương tính được xác định đúng chia cho tổng số kết quả được dự đoán là dương tính, bao gồm cả những trường hợp bị xác định sai; còn recall là số lượng kết quả dương tính được xác định đúng chia cho tổng số mẫu lẽ ra phải được xác định là dương tính. Vì lý do này, F1-score có xét đến cả false positive và false negative. So với accuracy, F1-score thường được ưu tiên sử dụng, đặc biệt trong các trường hợp có yếu tố chi phí hoặc dữ liệu mất cân bằng giữa các lớp. Trong trường hợp false positive và false negative có chi phí tương đương nhau, accuracy thường được ưu tiên.

$$\text{F1 Score} = \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Ví dụ trực quan:

Giả sử tập test có 100 ảnh.

Đối với lớp glioma

Thực tế có 20 ảnh glioma.

Model dự đoán:

- 18 ảnh được dự đoán là glioma
- Trong đó:
 - 15 ảnh đúng là glioma (TP = 15)
 - 3 ảnh thực ra là lớp khác (FP = 3)

Ngoài ra:

- Có 5 ảnh glioma bị dự đoán thành lớp khác (FN = 5)

Ta có:

Precision

Precision trả lời câu hỏi:

Trong số các ảnh được dự đoán là glioma, có bao nhiêu ảnh thật sự là glioma?

$$Precision = \frac{TP}{TP + FP}$$

$$Precision = \frac{15}{15 + 3} = \frac{15}{18} = 0.8333$$

Precision = 83.33%

Recall

Recall trả lời câu hỏi:

Trong tất cả các ảnh glioma thực sự tồn tại, model tìm được bao nhiêu?

$$Recall = \frac{TP}{TP + FN}$$

$$Recall = \frac{15}{15 + 5} = \frac{15}{20} = 0.75$$

Recall = 75%

F1-score

Là trung bình điều hòa giữa Precision và Recall.


$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$
$$F1 = \frac{2 \times 0.8333 \times 0.75}{0.8333 + 0.75} = 0.789$$

F1-score $\approx$ 78.9%

4.2. Metrics cho bài toán phân đoạn

Đối với bài toán phân đoạn u não

Dice coefficient: được sử dụng để so sánh sự trùng khớp từng pixel giữa phân đoạn dự đoán và dữ liệu thực tế tương ứng.



Công thức:


$$\frac{2 * |X \cap Y|}{|X| + |Y|}$$

trong đó X là tập hợp các pixel được dự đoán và Y là dữ liệu thực tế.

Intersection over Union (IoU): IoU được tính bằng cách chia phần trùng lặp giữa chú thích dự đoán và chú thích thực tế cho hợp của chúng.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Formal Intersection over Union formula




Visualized Intersection over Union formula

Pixel Accuracy : đo tỷ lệ pixel được phân loại đúng trên toàn bộ ảnh. Tuy nhiên, chỉ số này có thể bị ảnh hưởng khi dữ liệu mất cân bằng (ví dụ vùng nền chiếm đa số).

III) Phân tích và thiết kế hệ thống

A. Kiến trúc hệ thống tổng thể



B. Thiết kế model

Dựa vào paper để implement model Unet và Attention Unet.

1. Classification model(Unet Encoder + Classifier)

- Sử dụng Unet encoder để trích xuất đặc trưng.
- Đầu phân loại là kết nối đầy đủ

```

self.classifier = nn.Sequential(
    nn.AdaptiveAvgPool2d((1, 1)), nn.Flatten(),
    nn.Linear(512, 256), nn.ReLU(), nn.Dropout(0.5),
    nn.Linear(256, n_classes)
)

```

2. Joint Training model

- Sử dụng Unet encoder cho cả hai task Classification + Segmentation.
- Nhưng decoder riêng biệt cho Classification và Segmentation.
- Sử dụng Hard parameter sharing

```

class UnetWithClassifier(nn.Module):
    def
__init__(self, n_channels=1, n_seg_classes=1, n_clf_classes=4, bilinear=False)
:
    super().__init__()
    self.inp = DoubleConv(n_channels, 64)
    self.down1 = Down(64, 128)
    self.down2 = Down(128, 256)
    self.down3 = Down(256, 512)
    factor = 2 if bilinear else 1
    self.down4 = Down(512, 1024//factor)
    self.up1 = Up(1024, 512 // factor, bilinear)
    self.up2 = Up(512, 256 // factor, bilinear)
    self.up3 = Up(256, 128//factor, bilinear)
    self.up4 = Up(128, 64, bilinear)
    self.outp = OutConv(64, n_seg_classes)
    self.classifier = nn.Sequential(
        nn.AdaptiveAvgPool2d((1, 1)), nn.Flatten(),
        nn.Linear(1024//factor, 512), nn.ReLU(), nn.Dropout(0.5),
        nn.Linear(512, n_clf_classes)
    )

    def forward(self, x):
        x1 = self.inp(x)
        x2 = self.down1(x1)
        x3 = self.down2(x2)
        x4 = self.down3(x3)
        x5 = self.down4(x4)
        clf = self.classifier(x5) # determine tumor category
        x = self.up1(x5, x4)

```

```

x = self.up2(x, x3)
x = self.up3(x, x2)
x = self.up4(x, x1) # generating mask
return self.outp(x), clf

```

IV) Kết quả cài đặt và thử nghiệm

A. Chiến lược Training

Classification Training

Parameter	Value
Learning rate	0.0001
Batch size	32
Optimizer	AdamW
Weight Decay	0.001
Loss function	CrossEntropyLoss
Early Stopping	Patience = 10
Epochs	40

Segmentation Training

Parameter	Value
Learning rate	0.001
Batch size	12
Optimizer	AdamW
Weight Decay	0.001
Loss function	BCE + Dice Loss
Scheduler	ReduceLROnPlateau
Early stopping	Patience = 10
Epochs	40

Joint Training

Parameter	Value
Learning rate	0.001
Batch size	12
Optimizer	AdamW
Weight Decay	0.001
Loss function	BCE + Dice Loss + CrossEntropyLoss
Combined Metric	$0.6 * mIoU + 0.4 * Accuracy$
Scheduler	ReduceLROnPlateau
Early stopping	Patience = 10
Epochs	40

Data Augmentation

Để tăng độ đa dạng dữ liệu và giảm hiện tượng overfitting, các kỹ thuật Data Augmentation được áp dụng trong quá trình huấn luyện bằng thư viện Albumentations.

Classification

Các phép biến đổi gồm:

- Horizontal Flip
- Affine Transformation (scale, translation, rotation)
- Random Brightness & Contrast
- Gaussian Noise
- Gaussian Blur
- CLAHE
- Chuyển ảnh sang tensor bằng ToTensorV2()

Các phép augmentation giúp mô hình tăng khả năng nhận diện khối u trong nhiều điều kiện ảnh MRI khác nhau.

Segmentation

Đối với bài toán phân đoạn, augmentation được áp dụng đồng thời lên ảnh và mask, bao gồm:

- Horizontal Flip
- Affine Transformation
- Elastic Transform
- Random Brightness & Contrast
- Gaussian Noise
- Gaussian Blur
- Chuyển sang tensor bằng ToTensorV2()


Các phép biến đổi này giúp mô hình học được nhiều hình dạng và vị trí khối u khác nhau, từ đó cải thiện khả năng phân đoạn.





Hardware

- GPU : NVIDIA GeForce RTX 4050 Laptop GPU

- Framework : Pytorch 2.5.1 with CUDA 12.1

Training Curves





B.Kết quả thử nghiệm

1. Segmentation


Model	Val mIoU	Test mIoU	Test Dice	Test Pixel Acc
U-Net	0.6965	0.7409	0.8445	0.9948
Attention U-Net	0.7001	0.7430	0.8446	0.9949
Joint Training	0.6909	0.7438	0.8459	0.9949

- Test performance vượt trội hơn validation, điều này biểu thị training tốt.
- Attention U-Net(74.30% mIoU,84.46% Dice) đạt được test performance tốt hơn nhẹ U-Net(74.09% mIoU,84.45% Dice). Chênh lệch 0.21% mIoU.
- Kích thước của dataset có thể hạn chế những lợi ích của cơ chế Attention, model Attention U-Net chưa phát huy hết khả năng.
- Joint Training có test performance tốt nhất(74.38% mIoU,84.59% Dice) mặc dù Val mIoU là thấp nhất trong 3 model.Điều này chứng minh Joint Training cung cấp Regularization chống overfitting.

2. Classification

Model	Test Accuracy	Precision	Recall	F1-Score
U-NetClassifier	0.9050	0.9080	0.9050	0.9025
Joint Training	0.9733	0.9732	0.9733	0.9732


- Joint Training cải thiện 6.83% Accuracy so với Separate Training(U-Net Classifier).
- Các metric Precision,Recall,F1-Score đều cải thiện rõ rệt đối với Joint Training



- Đường chéo chiếm nhiều ảnh được phân loại cho thấy độ chính xác cao

Mô hình phân loại trên cả 4 lớp dữ liệu (Glioma, Meningioma, No Tumor, Pituitary):

- **Lớp 3 (Pituitary):** Hiệu suất tuyệt đối **300/300** mẫu chính xác (100%), không bị nhận nhầm.
- **Lớp 2 (No Tumor):** Độ chính xác rất cao, đạt **139/140** mẫu đúng (chỉ nhầm 1 mẫu sang Meningioma).
- **Lớp 0 (Glioma) & Lớp 1 (Meningioma):** Có sự chồng lấn mạnh do tương đồng hình thái học MRI:
 - **Glioma (Lớp 0):** Đúng 232 mẫu; nhầm 18 mẫu sang Meningioma và 4 mẫu sang Pituitary.
 - **Meningioma (Lớp 1):** Đúng 234 mẫu; nhầm 15 mẫu sang Glioma, 24 mẫu sang No Tumor (bỏ sót bệnh) và 33 mẫu sang Pituitary.



- Cải thiện phân loại trên tất cả các lớp

Khi tinh chỉnh, rút gọn còn 3 lớp (Glioma, Meningioma, Pituitary), kết quả cải thiện vượt bậc:

- **Meningioma (Lớp 1):** Cải thiện rõ rệt nhất, số mẫu đúng tăng từ 234 lên **294/306**. Tỷ lệ bỏ sót bệnh (nhầm sang No Tumor) giảm mạnh từ 24 xuống còn 5 mẫu.
- **Glioma (Lớp 0):** Số mẫu đúng tăng từ 232 lên **244/254**. Ca nhận nhầm sang Meningioma giảm từ 18 xuống còn 10.
- **Pituitary (Lớp 2):** Đạt phong độ xuất sắc với **299/300** mẫu chính xác.

C. Hình ảnh demo

1. Giao diện Flask upload ảnh và process kết quả

127.0.0.1:5000

Brain Tumor Detection System


MRI Image

Choose File brisc2025_test_00903_pi_co_t1.jpg


Ground Truth Mask

Choose File brisc2025_test_00903_pi_co_t1.png

Preview:



Analyze



MRI View

Axial

Confidence: 62.50%

Best Model

Joint Model

Model Comparison






Model	Prediction	Confidence	Tumor %	Status
Joint Model	pituitary	99.54%	0.59%	Best
Attention U-Net	Segmentation Only	100.00%	0.66%	-
Base U-Net	Segmentation Only	100.00%	0.58%	-
Classifier	pituitary	92.83%	0.00%	-

Back

2. Hình ảnh kết quả so sánh giữa các model và ảnh overlay


OK MRI View: Axial | Confidence: 62.5%

Axial-Horizontal slice (top-down view)




Classification

No Class Output
(Segmentation Only)








Classification

No Class Output
(Segmentation Only)



Segmentation

No Mask Output
(Classifier Only)



GT (Blue) vs Prediction (Red)


OK MRI View: Axial | Confidence: 71.4%

Axial-Horizontal slice (top-down view)


BEST: Joint Model




LOW Tumor: 0.61%



[HIGH] meningioma: 87.1%



Attention U-Net




LOW Tumor: 0.60%



Classification

No Class Output
(Segmentation Only)

Base U-Net



LOW Tumor: 0.67%



Classification

No Class Output
(Segmentation Only)


Classifier




Segmentation

No Mask Output
(Classifier Only)


[MEDIUM] no_tumor: 61.6%



Original MRI




**Joint Model
Tumor: 0.61%**



GT (Blue) vs Prediction (Red)

**Attention U-Net
Tumor: 0.60%**







**Base U-Net
Tumor: 0.67%**





OK MRI View: Axial | Confidence: 62.5%

Axial-Horizontal slice (top-down view)
LOW Tumor: 0.56%



Classification

No Class Output
(Segmentation Only)





Classification

No Class Output
(Segmentation Only)



Segmentation


No Mask Output
(Classifier Only)





WARN MRI View: Coronal | Confidence: 60.0%

Coronal-Frontal slice (front-back view)


BEST: Joint Model




LOW Tumor: 0.00%



Attention U-Net




LOW Tumor: 0.00%




Classification

No Class Output
(Segmentation Only)

Base U-Net




LOW Tumor: 0.00%



Classification


No Class Output
(Segmentation Only)

Classifier







Segmentation

No Mask Output
(Classifier Only)





BAD MRI View: Axial | Confidence: 40.0%

Axial-Horizontal slice (top-down view)



Classification

No Class Output
(Segmentation Only)




Classification

No Class Output
(Segmentation Only)



Segmentation

No Mask Output
(Classifier Only)



V) Kết Luận

Nghiên cứu này đã cài đặt và đánh giá thành công một số cách tiếp cận deep learning cho phân tích u não.

Một số điểm quan trọng đạt được:

- Triển khai 4 model học sâu với kết quả tương đối tốt.
- Model tốt nhất cho Segmentation : Joint Training(0.7438 test mIoU, 0.8459 Dice, 0.9949 Pixel Accuracy).
- Đánh giá trên tập Test : 860 ảnh với khả năng generalization tốt.
- Model tốt nhất cho Classification : Joint Training(0.9733 Accuracy).
- Xây dựng hệ thống mô phỏng sẵn sàng triển khai thực tế.
- Test performance vượt trội hơn validation, điều này biểu thị training tốt.

TÀI LIỆU THAM KHẢO

Oktaý, O., Schlemper, J., Le Folgoc, L., Lee, M.J., Heinrich, M.P., Misawa, K., Mori, K., McDonagh, S.G., Hammerla, N.Y., Kainz, B., Glocker, B., & Rueckert, D. (2018). Attention U-Net: Learning Where to Look for the Pancreas. *ArXiv*, abs/1804.03999.

Fateh, A., Rezvani, Y., Moayedi, S., Rezvani, S., Fateh, F., & Fateh, M. (2025). BRISC: Annotated Dataset for Brain Tumor Segmentation and Classification. *Scientific Data*, 13.

Azad, R., Heidary, M., Yilmaz, K., Huttemann, M., Karimijafarbigloo, S., Wu, Y., Schmeink, A., & Merhof, D. (2023). Loss Functions in the Era of Semantic Segmentation: A Survey and Outlook. *ArXiv*, abs/2312.05391.

Kamiri, J., Wambugu, G.M., & Oirere, A.M. (2025). Multi-task Deep Learning in Medical Image Processing: A Systematic Review. *International Journal of Computing Sciences Research*.

Caruana, R. (1997). Multitask Learning. *Machine Learning*, 28, 41-75.

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *ArXiv*, abs/1505.04597.

Obi, J.C. (2023). A comparative study of several classification metrics and their performances on data. *World Journal of Advanced Engineering Technology and Sciences*.