

Đề tài: Multi-Task Learning for Brain Tumor Classification and Segmentation on BRISC 2025 Dataset

1. Giới thiệu dự án

1.1 Lý do chọn đề tài

U não (brain tumor) là một trong những bệnh lý nguy hiểm với tỷ lệ tử vong cao nếu không được phát hiện và điều trị kịp thời. Chẩn đoán u não thông qua ảnh MRI đòi hỏi chuyên môn cao và tốn nhiều thời gian của bác sĩ chuyên khoa thần kinh và chẩn đoán hình ảnh.

Trong những năm gần đây, học sâu (Deep Learning) đã chứng minh hiệu quả vượt trội trong phân đoạn (segmentation) và phân loại (classification) ảnh y tế, đặc biệt với kiến trúc U-Net do Olaf Ronneberger và cộng sự đề xuất (Ronneberger et al., 2015). Ngoài ra, phương pháp Multi-task Learning (Caruana, 1997) cho phép mô hình học đồng thời nhiều nhiệm vụ liên quan, từ đó cải thiện khả năng tổng quát hóa.

Do đó, đề tài này được lựa chọn nhằm:

- Xây dựng và so sánh nhiều kiến trúc deep learning cho bài toán segmentation và classification.
- So sánh huấn luyện riêng biệt (separate training) và huấn luyện đồng thời (joint multi-task learning).
- Đánh giá hiệu quả của Attention mechanism.
- So sánh CNN xây dựng từ đầu với ResNet theo hướng transfer learning.
- Triển khai hệ thống suy luận (inference) dưới dạng web application sử dụng Flask.

1.2 Ý nghĩa và tính ứng dụng

Ý nghĩa thực tiễn:

- Hỗ trợ bác sĩ trong việc xác định và khoanh vùng khối u nhanh chóng.
- Giảm thời gian phân tích ảnh.
- Tăng độ chính xác trong chẩn đoán.

Tính ứng dụng:

- Có thể tích hợp vào hệ thống hỗ trợ chẩn đoán lâm sàng.
- Có thể triển khai thành REST API phục vụ inference thời gian thực.

Giá trị học thuật:

- So sánh CNN cơ bản với U-Net trong ảnh y tế.
- So sánh CNN cơ bản với ResNet (He et al., 2016).
- Phân tích hiệu quả của Multi-task Learning.
- Đánh giá ảnh hưởng của Attention mechanism.
- So sánh giữa Separate vs Joint training.
- Xây dựng pipeline hoàn chỉnh từ nghiên cứu đến triển khai thực tế.

2. Cơ sở lý thuyết và công nghệ sử dụng

2.1 Cơ sở lý thuyết

2.1.1 Convolutional Neural Network (CNN)

CNN được đề xuất bởi Yann LeCun và cộng sự trong nghiên cứu về LeNet (LeCun et al., 1998). CNN sử dụng:

- Convolution layers để trích xuất đặc trưng
- Pooling layers để giảm chiều
- Fully connected layers cho phân loại

CNN là nền tảng cho hầu hết các kiến trúc segmentation hiện đại.

2.1.2 Residual Network (ResNet)

ResNet được đề xuất bởi He et al. (2016) nhằm giải quyết vấn đề vanishing gradient trong các mạng sâu. Kiến trúc này sử dụng residual connections (skip connections) cho phép mô hình học phần dư (residual mapping) thay vì học trực tiếp hàm ánh xạ đầy đủ.

Ưu điểm của ResNet:

- Huấn luyện mạng sâu hiệu quả hơn
- Giảm hiện tượng suy giảm độ chính xác khi tăng số tầng
- Phù hợp với transfer learning

Trong dự án này, ResNet được sử dụng cho bài toán classification và được fine-tune từ pretrained weights trên ImageNet để so sánh với CNN xây dựng từ đầu.

2.1.3 U-Net Architecture

U-Net là kiến trúc encoder-decoder với skip connections được đề xuất trong lĩnh vực segmentation ảnh y tế (Ronneberger et al., 2015).

Đặc điểm chính:

- Cấu trúc đối xứng encoder-decoder
- Skip connections giúp bảo toàn thông tin không gian
- Phù hợp với dữ liệu y tế có kích thước nhỏ

2.1.4 Attention U-Net

Attention U-Net được đề xuất bởi Ozan Oktay và cộng sự (Oktay et al., 2018).

Attention gate giúp:

- Tập trung vào vùng quan trọng
- Giảm nhiễu nền
- Cải thiện Dice score trong segmentation

2.1.5 Multi-task Learning

Multi-task Learning (MTL) được hệ thống hóa bởi Rich Caruana (1997).

MTL cho phép:

- Chia sẻ encoder giữa nhiều nhiệm vụ
- Giảm overfitting
- Cải thiện khả năng tổng quát hóa

Trong dự án này, classification và segmentation sẽ dùng chung encoder.

2.1.6 Loss Functions

- Binary Cross Entropy (BCE)
- Dice Loss (Milletari et al., 2016)
- CrossEntropy Loss với class weighting

2.2 Công nghệ sử dụng

- Python
- PyTorch
- NumPy
- OpenCV
- Matplotlib
- Flask

2.3 Dataset sử dụng

Dự án sử dụng bộ dữ liệu BRISC 2025: Brain Tumor MRI Dataset for Segmentation and Classification được công bố trên *Scientific Data (Nature Portfolio)* (Fateh et al., 2025). BRISC là bộ dữ liệu MRI não chất lượng cao, được chú thích (annotation) bởi các bác sĩ chuyên khoa và chuyên gia chẩn đoán hình ảnh.

Các đặc điểm chính của dataset:

- Tổng số ảnh: 6.000 ảnh MRI T1-weighted
- Tập huấn luyện: 5.000 ảnh
- Tập kiểm thử: 1.000 ảnh
- 4 lớp phân loại: Glioma, Meningioma, Pituitary Tumor và No Tumor
- Có mặt nạ segmentation ở mức pixel (pixel-wise annotation)
- Ảnh thuộc ba mặt phẳng giải phẫu: Axial, Coronal và Sagittal
- Phân bố lớp được thiết kế cân bằng

Dataset được tổ chức thành hai nhiệm vụ riêng biệt:

1. Classification task: Dữ liệu được sắp xếp theo thư mục tương ứng với từng lớp.
2. Segmentation task: Bao gồm cặp ảnh MRI và mặt nạ nhị phân tương ứng.

BRISC được thiết kế đặc biệt phù hợp cho các bài toán multi-task learning vì cung cấp đồng thời nhãn phân loại và mặt nạ phân đoạn cho cùng một tập ảnh MRI.

3. Phân tích yêu cầu dự án

3.1 Yêu cầu chức năng

3.1.1 Xây dựng mô hình

Triển khai và so sánh 6 kiến trúc:

1. CNN scratch – Classification
2. ResNet (Transfer Learning) – Classification
3. Standard U-Net – Segmentation
4. U-Net Encoder + Classifier
5. Joint Multi-task Model
6. Attention U-Net – Segmentation

3.1.2 Đánh giá mô hình

Các chỉ số đánh giá:

- Accuracy
- F1-score
- Dice coefficient
- IoU
- Confusion matrix

So sánh:

- Separate training vs Joint training
- Có Attention vs Không Attention
- CNN vs Resnet

3.1.3 Triển khai hệ thống bằng Flask

Hệ thống gồm:

User → Web Interface → Flask API → Load Model → Inference → Return Result

Chức năng:

- Upload ảnh MRI
- Tiền xử lý ảnh
- Dự đoán class
- Sinh segmentation mask
- Hiển thị kết quả trực quan

3.2 Yêu cầu phi chức năng

- Code modular và dễ mở rộng
- Mô hình có khả năng tổng quát hóa
- Giao diện web đơn giản, dễ sử dụng

4. Kế hoạch thực hiện dự án

Giai đoạn 1: Chuẩn bị dữ liệu

- Tiền xử lý dữ liệu
- Data augmentation
- Chia tập train/validation/test

Giai đoạn 2: Baseline Models

- Xây dựng CNN scratch
- Finetune Resnet
- Triển khai Standard U-Net
- Đánh giá kết quả ban đầu

Giai đoạn 3: Multi-task Learning

- Thiết kế shared encoder
- Huấn luyện joint model
- Tuning loss weight
- So sánh Separate vs Joint

Giai đoạn 4 : Attention Mechanism

- Triển khai Attention U-Net
- So sánh Dice score
- Phân tích improvement.

Giai đoạn 5: Deployment

- Lưu best model
- Xây dựng Flask API
- Thiết kế giao diện upload ảnh
- Test inference pipeline

Giai đoạn 6 : Tổng hợp và viết báo cáo

- Vẽ biểu đồ so sánh
- Phân tích kết quả
- Hoàn thiện báo cáo cuối kỳ

Tài liệu tham khảo

Caruana, R. Multitask Learning. *Machine Learning* 28, 41–75 (1997).
[10.1023/A:1007379606734](https://doi.org/10.1023/A:1007379606734)

Fateh, A., et al. (2025). BRISC 2025: Brain tumor MRI dataset for segmentation and classification. *Scientific Data*.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 770–778). [10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90)

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.
<https://doi.org/10.1109/5.726791>

Milletari, F., Navab, N., & Ahmadi, S.-A. (2016). V-Net: Fully convolutional neural networks for volumetric medical image segmentation. In *2016 Fourth International Conference on 3D Vision (3DV)* (pp. 565–571). IEEE. [10.48550/arXiv.1606.04797](https://arxiv.org/abs/1606.04797)

Oktay, O., Schlemper, J., Folgoc, L. L., et al. (2018). Attention U-Net: Learning where to look for the pancreas. [10.48550/arXiv.1804.03999](https://arxiv.org/abs/1804.03999)

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)* (pp. 234–241). Springer. [10.1007/978-3-319-24574-4_28](https://doi.org/10.1007/978-3-319-24574-4_28)