

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỀ CƯƠNG THỰC TẬP CƠ SỞ

ĐỀ TÀI:

**Nghiên cứu học đa nhiệm và cơ chế Attention trong bài toán
phân đoạn và phân loại u não từ ảnh MRI**

Giảng viên hướng dẫn: TS.Kim Ngọc Bách

Sinh viên thực hiện: Đặng Tuấn Minh

Mã Sinh Viên: B23DCCN539

HÀ NỘI, THÁNG 3/2026

Báo cáo tuần 3

I) Công việc hoàn thành

1. Custom Dataset và Data Augmentation

Trong tuần vừa qua, em đã tập trung xây dựng module xử lý dữ liệu phục vụ cho bài toán phân loại và phân đoạn ảnh MRI não. Cụ thể, em đã triển khai hai lớp Dataset sử dụng PyTorch gồm ClassificationDataset và SegmentationDataset nhằm tổ chức và đọc dữ liệu từ thư mục theo từng tập train/validation.

Đối với bài toán phân loại, em đã xây dựng cơ chế đọc dữ liệu từ file .npy, ánh xạ nhãn thông qua file class_mapping.json, đồng thời xử lý mất cân bằng dữ liệu bằng cách tính toán trọng số lớp (class weights). Với bài toán phân đoạn, em đã xây dựng pipeline đọc cặp ảnh-mask tương ứng và đảm bảo dữ liệu được đồng bộ khi huấn luyện.

Ngoài ra, em đã áp dụng thư viện Albumentations để xây dựng các phép tăng cường dữ liệu (data augmentation) như lật ảnh, xoay, biến dạng hình học, thay đổi độ sáng, thêm nhiễu,... giúp tăng tính đa dạng của dữ liệu và cải thiện khả năng tổng quát hóa của mô hình. Dữ liệu sau khi xử lý được chuyển đổi sang tensor để phục vụ cho quá trình huấn luyện mô hình học sâu.

Kết quả đạt được là hoàn thiện pipeline tiền xử lý và chuẩn bị dữ liệu cho cả hai bài toán classification và segmentation, sẵn sàng tích hợp vào quá trình huấn luyện mô hình.

2. Triển khai mô hình Unet và UnetClassifier

Em tiếp tục phát triển phần mô hình học sâu cho bài toán phân loại và phân đoạn ảnh MRI não. Cụ thể, em đã xây dựng kiến trúc U-Net hoàn chỉnh bằng PyTorch, bao gồm các thành phần như DoubleConv, Down, Up và OutConv, nhằm thực hiện bài toán phân đoạn ảnh với cơ chế skip connection giúp bảo toàn thông tin không gian.

Bên cạnh đó, em cũng triển khai một biến thể của U-Net cho bài toán phân loại (UnetClassifier), trong đó sử dụng phần encoder của U-Net kết hợp với các lớp fully connected để thực hiện phân loại ảnh thành các lớp khối u não khác nhau. Mô hình sử dụng các kỹ thuật như Batch Normalization, ReLU và Dropout nhằm cải thiện hiệu năng và giảm overfitting.

Kết quả đạt được là xây dựng thành công hai mô hình cho hai bài toán segmentation và classification, sẵn sàng tích hợp vào pipeline huấn luyện và đánh giá trong các bước tiếp theo.

3. Tìm hiểu về các hàm mất mát sử dụng trong dự án

3.1) Cross-Entropy Loss

Entropy chéo (CE) đo lường sự khác biệt giữa hai phân phối xác suất cho một biến ngẫu nhiên nhất định. Trong các nhiệm vụ phân đoạn, tổn thất entropy chéo được sử dụng để đo lường mức độ phù hợp giữa dự đoán của mô hình với nhãn mục tiêu. Sử dụng hàm softmax, mô hình tạo ra bản đồ xác suất theo từng pixel thể hiện khả năng mỗi pixel thuộc về mỗi lớp. Sau đó, tổn thất entropy chéo được tính bằng cách lấy logarit âm của xác suất dự đoán cho lớp mục tiêu tại mỗi pixel. Tổn thất entropy chéo tiến đến 0 khi xác suất dự đoán cho lớp mục tiêu tiến đến 1.

$$L_{CE}(y, t) = - \sum_{n=1}^N \log(t_n \cdot y_n) \quad (1)$$

As t_n is a one-hot encoded vector, only the predicted probability of the target class affects the cross-entropy loss.

Khi xử lý các tập dữ liệu không cân bằng, một cách tiếp cận đối với hàm mất mát entropy chéo là gán trọng số khác nhau cho mỗi lớp. Điều này có thể giúp cân bằng ảnh hưởng của mỗi lớp đến tổn thất tổng thể và cải thiện hiệu suất của mô hình trên các lớp ít được đại diện. Một cách để gán trọng số là sử dụng tần suất nghịch đảo của lớp, có nghĩa là trọng số cho mỗi lớp tỷ lệ nghịch với số lượng mẫu trong lớp đó. Vì vậy, các lớp có ít mẫu hơn sẽ có trọng số cao hơn và các lớp có nhiều mẫu hơn sẽ có trọng số thấp hơn.

$$L_{WCE}(y, t, w) = - \sum_{n=1}^N t_n \cdot w \log(t_n \cdot y_n) \quad (2)$$

Đối với mỗi pixel, trọng số của lớp mục tiêu được sử dụng. Nếu tất cả các trọng số được đặt bằng 1, ta chỉ đơn giản nhận được tổn thất entropy chéo.

3.2) Dice Loss

Hàm mất mát Dice bắt nguồn từ hệ số Dice, một thước đo độ tương đồng giữa hai tập dữ liệu. Nó thường được sử dụng trong phân đoạn ảnh để đánh giá sự chồng chéo giữa mặt nạ phân đoạn dự đoán và mặt nạ phân đoạn mục tiêu. Nó được định nghĩa là kích thước của phần giao nhau giữa mặt nạ phân đoạn dự đoán và mặt nạ phân đoạn thực tế, chia cho tổng của chúng. Nó được tính toán riêng cho từng lớp và giá trị trung bình được báo cáo. Nó có thể được viết như sau:

$$\text{Dice Coefficient} = \frac{2|Y \cap T|}{|Y| + |T|} \quad (6)$$

trong đó Y là mặt nạ dự đoán phân đoạn nhị phân và T là mặt nạ mục tiêu phân đoạn nhị phân cho một lớp duy nhất. Hệ số Dice thường được sử dụng trong phân đoạn ngữ nghĩa vì nó dễ

tính toán, cung cấp một giá trị duy nhất tóm tắt hiệu suất và đạt được sự cân bằng tốt giữa độ chính xác và độ thu hồi. Nó đặc biệt hữu ích khi đối tượng quan tâm nhỏ hoặc hiếm và sự phân bố lớp không cân bằng.

Nó được tính toán riêng cho từng lớp mục tiêu và giá trị trung bình trên tất cả các lớp được sử dụng. Các dự đoán không được coi là chắc chắn (0, 1) mà được nói lỏng và được coi là xác suất (0, 1). Điều này làm cho hàm mất mát trở nên khả vi và có thể được tối ưu hóa bằng các phương pháp giảm độ dốc. Cuối cùng, hệ số Dice được nói lỏng được trừ đi 1 để biến nó thành một hàm mất mát cần được tối thiểu hóa thay vì tối đa hóa. Đây là một lựa chọn phổ biến cho các tập dữ liệu không cân bằng vì nó ngăn mô hình bỏ qua các lớp thiểu số bằng cách tập trung vào các vùng chồng chéo giữa mặt nạ dự đoán và mặt nạ thực tế.

4. Evaluation metrics

4.1. Metrics cho bài toán phân loại

Đối với bài toán phân loại khối u não, các chỉ số sau được sử dụng:

- **Accuracy:** đo tỷ lệ dự đoán đúng trên toàn bộ tập dữ liệu.
- **Precision:** đo độ chính xác của các dự đoán thuộc từng lớp, được tính theo trung bình có trọng số (*weighted average*) để xử lý mất cân bằng dữ liệu.
- **Recall:** đo khả năng mô hình phát hiện đúng các mẫu thuộc từng lớp, đặc biệt quan trọng trong bài toán y tế nhằm tránh bỏ sót bệnh.
- **F1-score:** là trung bình điều hòa giữa Precision và Recall, phản ánh sự cân bằng giữa hai chỉ số này.
- **Confusion Matrix:** cung cấp cái nhìn chi tiết về số lượng dự đoán đúng và sai giữa các lớp, giúp phân tích lỗi của mô hình.

4.2. Metrics cho bài toán phân đoạn ảnh

Đối với bài toán segmentation, các chỉ số đánh giá được tính ở mức pixel:

- **Dice Coefficient:** đo độ chồng lấp giữa vùng dự đoán và ground truth. Giá trị càng gần 1 cho thấy kết quả phân đoạn càng chính xác.

$$Dice = \frac{2 \times |P \cap G|}{|P| + |G|}$$

- **Intersection over Union (IoU):** đo tỷ lệ giữa phần giao và phần hợp của hai vùng, là một metric nghiêm ngặt hơn Dice.

$$\text{Intersection over Union} = \frac{|Y \cap T|}{|Y \cup T|}$$

- **Pixel Accuracy:** đo tỷ lệ pixel được phân loại đúng trên toàn bộ ảnh. Tuy nhiên, chỉ số này có thể bị ảnh hưởng khi dữ liệu mất cân bằng (ví dụ vùng nền chiếm đa số).

II) Mục tiêu tuần tiếp theo

1. Hoàn thành implement các hàm mất mát và đánh giá
2. Triển khai mô hình AttentionUnet và Multitask
3. Viết train loop và val loop

Tài liệu tham khảo

Azad, R., Heidary, M., Yilmaz, K., Huttemann, M., Karimijafarbigloo, S., Wu, Y., Schmeink, A., & Merhof, D. (2023). Loss Functions in the Era of Semantic Segmentation: A Survey and Outlook. ArXiv, abs/2312.05391.