

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỀ CƯƠNG THỰC TẬP CƠ SỞ

ĐỀ TÀI:

**Nghiên cứu học đa nhiệm và cơ chế Attention trong bài toán
phân đoạn và phân loại u não từ ảnh MRI**

Giảng viên hướng dẫn: TS.Kim Ngọc Bách

Sinh viên thực hiện: Đặng Tuấn Minh

Mã Sinh Viên: B23DCCN539

HÀ NỘI, THÁNG 3/2026

Báo cáo tuần 4

I) Công việc hoàn thành

1. Tìm hiểu về Multitask Learning trong Medical Imaging

Giới thiệu


Học đa nhiệm (MTL) là một phương pháp học sâu nhằm mục đích học đồng thời hai hoặc nhiều nhiệm vụ cùng nhau để tận dụng kiến thức được chia sẻ giữa các nhiệm vụ. Kiến thức được chia sẻ này giúp cải thiện hiệu suất của từng nhiệm vụ. Theo truyền thống, các mô hình học sâu được huấn luyện để thực hiện một nhiệm vụ duy nhất; tuy nhiên, các mô hình đơn nhiệm truyền thống này yêu cầu rất nhiều dữ liệu huấn luyện, điều này không dễ dàng có được trong một số lĩnh vực như y học và tin sinh học.

1.1 Phương pháp MTL Learning

Có bốn phương pháp học chính cho MTL, đó là hard parameter sharing, soft parameter sharing, multi-task attention network, and cross-task attention network.

Hard parameter sharing

Hard parameter sharing trong MTL liên quan đến việc chia sẻ các lớp chung giữa các tác vụ, đặc biệt là các lớp trích xuất đặc trưng, và sau đó mô hình phân nhánh thành các lớp dành riêng cho từng tác vụ như thể hiện trong Hình 3. Chia sẻ tham số cứng cho phép mô hình tìm ra một biểu diễn tổng quát hơn cho tất cả các tác vụ, do đó giảm thiểu nguy cơ quá khớp. Tuy nhiên, cần phải xem xét tính hợp tác so với tính cạnh tranh của các tác vụ liên quan khi thiết kế MTL chia sẻ tham số cứng. Điều này là do chia sẻ tham số cứng là một phương pháp học đặc trưng tập trung vào việc học các đặc trưng chung giữa các tác vụ. Do đó, các tác vụ cạnh tranh sẽ dẫn đến hiệu suất kém vì mô hình sẽ phải vật lộn để đạt được điểm cực tiểu toàn cục của các tác vụ cạnh tranh.



Hình 3

Soft parameter sharing


Soft parameter sharing liên quan đến việc mỗi tác vụ có mô hình và tham số riêng nhưng kiến thức được chia sẻ giữa các tác vụ thông qua regularization. Các kỹ thuật chuẩn hóa phổ biến có thể được sử dụng bao gồm L1 (còn gọi là Lasso) và L2 (còn gọi là chuẩn hóa Ridge). L1 điều chỉnh hàm mất mát bằng cách thêm một số hạng phạt bằng với giá trị tuyệt đối của trọng số của hàm mất mát. Nó có thể được biểu diễn bằng toán học như sau:

$$Loss (L1) = Loss (X) + \lambda \sum_i |w_i|.$$

Mặt khác, L2 lập luận về hàm mất mát bằng cách thêm một hình phạt bằng tổng bình phương các giá trị của hàm mất mát. Nó có thể được biểu diễn bằng toán học như sau:

$$Loss (L2) = Loss (X) + \lambda \sum_i |w_i^2|.$$

Loss (X) biểu thị hàm mất mát gốc như mất mát entropy chéo hoặc sai số bình phương trung bình, λ biểu thị một siêu tham số xác định độ mạnh của việc điều chỉnh và các hệ số của mô hình được biểu thị bằng w_i .



Multi-task attention network

Multi-task attention network (MTAN) được giới thiệu bởi Liu et al., (2019) bao gồm các lớp trích xuất đặc trưng được chia sẻ nhưng với cơ chế chú ý mềm cho mỗi nhiệm vụ. Cơ chế chú ý cho phép tối ưu hóa việc học các đặc trưng cụ thể của nhiệm vụ từ bộ trích xuất đặc trưng được chia sẻ trong khi vẫn cho phép các đặc trưng được chia sẻ giữa các nhiệm vụ.. Kim et al., (2023) lập luận rằng mặc dù MTAN đã trở nên rất phổ biến trong xử lý ảnh phi y tế do khả năng phân tích các đặc trưng cấp pixel, nhưng nó gặp khó khăn trong lĩnh vực xử lý ảnh y tế vì nhiều ảnh y tế thiếu các đặc trưng cấp pixel rõ ràng. Để giải quyết khoảng trống này, Kim et al., (2023) đã đề xuất một mạng chú ý đa nhiệm (CTAN).

Cross-task attention network

Cross-task attention network (CTAN) là một khung lai có thể xử lý cả các đặc trưng cấp độ hình ảnh và các đặc trưng cấp độ pixel. Nó bao gồm một bộ mã hóa chú ý đa nhiệm và một nút thắt chú ý đa nhiệm. Bộ mã hóa chú ý đa nhiệm trích xuất thông tin cụ thể của nhiệm vụ trong bộ mã hóa theo cách tương tự như các mô-đun chú ý trong MTAN. Nút thắt chú ý đa nhiệm nắm bắt các tương tác giữa các nhiệm vụ.

Trong dự án này, em sử dụng phương pháp Hard parameter sharing vì model của em sử dụng Unet chia sẻ phần encoder cho cả 2 task: phân loại và phân đoạn, và chia ra các đầu giải mã riêng biệt cho mỗi task.

1.2 Task Combinations

Standley và cộng sự (2020) lập luận rằng trong thiết lập MTL, tất cả các tác vụ đều có khả năng cải thiện hiệu suất nếu chúng hợp tác với nhau tác vụ. Cũng có thể một số tác vụ hỗ trợ các tác vụ khác cải thiện hiệu suất trong khi bản thân chúng không cải thiện hiệu suất. Những tác vụ như vậy được gọi là tác vụ hướng dẫn mất mát hoặc tác vụ dư thừa. Trong lĩnh vực xử lý hình ảnh y tế, nhiều tác vụ đơn lẻ có thể được đưa vào thiết lập đa tác vụ. Chúng bao gồm; phân đoạn, phân loại, hồi quy, phát hiện đối tượng và tái tạo, trong số những tác vụ khác.

Rõ ràng là việc xác định các nhiệm vụ cần đưa vào mô hình MTL nên được dựa trên việc liệu các nhiệm vụ đó có thể được chia thành các nhiệm vụ riêng lẻ hay không. Do đó, một mô hình MTL có thể được coi là đúng nếu mỗi nhiệm vụ có thể được liên kết với một hàm mất mát. Một chủ đề đáng chú ý trong nghiên cứu này là để quá trình học tập chung diễn ra, phần lớn các nghiên cứu được xem xét đã xây dựng một hàm mất mát kết hợp xem xét các hàm mất mát cụ thể của từng nhiệm vụ. Ví dụ: cho ba nhiệm vụ T_a , T_b và T_c , và cho các hàm mất mát của chúng là L_a , L_b và L_c , thì hàm mất mát kết hợp có thể được xây dựng như sau:

$$L_{\text{combined}} = \lambda_1 L_a + \lambda_2 L_b + \lambda_3 L_c$$

Trong đó λ_1 , λ_2 và λ_3 là các trọng số cho từng hàm mất mát riêng lẻ.

2. Triển khai dự án

Triển khai các hàm mất mát và đánh giá

Triển khai mô hình Attention Unet và Multitask Learning

Triển khai train loop, val loop cho cả 4 model:

- **Classification model:** Unet Encoder + Classifier
- **Segmentation model:** Standard Unet
- **Joint Training model:**
 - + Shared encoder for both tasks
 - + Separate decoder heads for classification and segmentation
- **Attention U-net**

II) Kế hoạch tuần tiếp theo

1. Thực hiện huấn luyện các model và lưu lại checkpoint

Tài liệu tham khảo

Kamiri, J., Wambugu, G.M., & Oirere, A.M. (2025). Multi-task Deep Learning in Medical Image Processing: A Systematic Review. International Journal of Computing Sciences Research.